

# Proposta Técnica

Automação de Pedidos por IA



softeum

**{{CLIENTE\_RAZAO\_SOCIAL}}**

Proposta {{NUMERO\_PROPOSTA}}

versão {{VERSAO}}

**{{CIDADE}}, {{DATA}}**

# 1 VISÃO GERAL DO PRODUTO

A **Softeum** é uma plataforma SaaS multi-tenant que automatiza o recebimento e o processamento de pedidos de compra. A solução monitora as caixas de e-mail e os números de WhatsApp cadastrados de cada empresa cliente, usa inteligência artificial para extrair os pedidos de arquivos (PDF e imagem) e de mensagens de texto, aplica um de-para inteligente contra o catálogo do próprio cliente e envia o pedido normalizado ao ERP, de forma idempotente.

O objetivo é eliminar a digitação manual de pedidos e o retrabalho. Os seguintes formatos de entrada são processados:

- **Pedido em PDF** — documentos nativos ou escaneados; cada página é lida diretamente pela IA multimodal.
- **Pedido em imagem** — fotos ou prints de pedidos, com pré-processamento/OCR quando a qualidade exige.
- **Pedido no corpo do e-mail** — texto livre extraído e estruturado.
- **Pedido por WhatsApp** — mensagens tratadas por um agente de IA que tira o pedido e confirma os dados antes de finalizar.
- **Anexos de e-mail** — armazenados em bucket privado com deduplicação por hash; o pedido guarda apenas a referência ao arquivo.

## 2 MODELO DE OFERTA

A plataforma é ofertada por módulos, contratados de forma independente. Cada módulo habilita a respectiva caixa de entrada (inbox) no painel do cliente:

- **Módulo E-mail** — monitora caixas Gmail (API + Pub/Sub) e Outlook (Microsoft Graph), sem polling. Ingestão por webhook com varredura de reconciliação de garantia.
- **Módulo WhatsApp** — número oficial via WhatsApp Business Cloud API (Meta), com um agente de IA que tira pedidos, tira dúvidas e sempre confirma o pedido com os dados cadastrais antes de finalizar.

## 3 MODELO OPERACIONAL

O fluxo de ponta a ponta é idempotente — reprocessar uma mensagem nunca duplica o pedido no ERP:

- **1. Ingestão** — o e-mail/WhatsApp de um remetente cadastrado dispara um webhook, tratado por uma Edge Function que deduplica (message-id / wamid) e enfileira.
- **2. Reconciliação** — a cada poucos minutos, uma varredura confere a caixa no provedor e recupera qualquer mensagem que o webhook tenha perdido — nada se perde.
- **3. Extração por IA** — o worker lê o documento e extrai itens, cliente, condições e datas em JSON estruturado, validado por schema.
- **4. De-para** — cada item é casado contra o catálogo por camadas: código/EAN/alias exato, fuzzy, semântico e desambiguação por LLM entre candidatos do catálogo.
- **5. Revisão** — itens com confiança abaixo do limite vão para revisão humana no painel; acima do limite seguem automaticamente.
- **6. Envio ao ERP** — o pedido normalizado é entregue ao ERP (pull pela API ou push no endpoint), de forma idempotente.
- **7. Notificação** — o comprador recebe e-mails automáticos: pedido recebido e, depois, aprovado ou reprovado com o motivo.

**Máquina de estados:** RECEBIDO → EXTRAINDO → EXTRAÍDO → DEPARA\_PENDENTE → EM\_REVISÃO → PRONTO → ENVIANDO\_ERP → CONCLUÍDO. Terminais: ERRO (falha do sistema), NÃO\_PEDIDO (não era pedido) e REPROVADO (decisão do revisor, notifica o comprador).

## 4 ARQUITETURA E INFRAESTRUTURA

| Camada                            | Tecnologia                                                                 |
|-----------------------------------|----------------------------------------------------------------------------|
| Frontend                          | React + TypeScript + Vite (aplicação única com rotas por perfil)           |
| Auth · Banco · Storage · Realtime | Supabase (PostgreSQL) com RLS obrigatório em todas as tabelas              |
| Fila durável                      | Filas nativas do Postgres (pgmq), uma por etapa, particionadas por cliente |

|                          |                                                                  |
|--------------------------|------------------------------------------------------------------|
| Workers de processamento | Node/TypeScript containerizados, escala horizontal, idempotentes |
| Ingestão leve            | Edge Functions (apenas webhooks e enfileiramento)                |
| Busca semântica          | pgvector (embeddings do catálogo) no próprio Postgres            |
| IA de extração           | modelos multimodais de ponta, com fallback entre provedores      |
| Cobrança                 | Asaas (Pix, boleto e cartão)                                     |

Escala projetada: 50 clientes ativos e ~100.000 pedidos/dia, com filas e limite de concorrência por cliente — o pico de um cliente não consome a frota inteira.

## 5 MÓDULOS DO PRODUTO

- **Painel do Cliente** — pedidos por status, dashboard, catálogo, clientes finais, de-para, configurações e inboxes.
- **Painel Superadmin** — gestão de clientes, ativação de módulos, financeiro, saúde do sistema e notificações de erro.
- **Motor de Extração por IA** — leitura multimodal de PDF/imagem/texto com saída estruturada validada.
- **Camada de Layout Aprendido** — aprende a receita de cada layout e passa a lê-lo sem IA, a custo zero.
- **Motor de De-para Inteligente** — casamento por múltiplas camadas contra o catálogo, com aprendizado contínuo.
- **Conector de ERP** — API self-service documentada (pull) e envio Generic REST/Webhook (push).
- **Agente de WhatsApp** — atendimento ativo com guardrails e confirmação obrigatória do pedido.
- **Monitoramento e Eventos** — registro de erros, custo de IA e sinal de vida dos processos.

## 6 PERFIS DE USUÁRIO

- **Superadmin (Softeum)** — cadastra clientes, ativa módulos, cuida do financeiro e recebe as notificações de erro.
- **Admin de TI** — administrador do cliente com permissão de ERP; único que configura a integração e gera chaves de API.
- **Admin** — administrador do cliente sem acesso à configuração de ERP.
- **Operador** — vê e revisa apenas os pedidos das caixas que ele próprio conectou.

## 7 PRINCIPAIS FUNCIONALIDADES

- **Extração por IA multimodal** — leitura direta de PDF, imagem e texto, com modelo primário rápido, classificador leve e fallback para documentos difíceis.
- **Layout aprendido (extração sem IA)** — a receita de um layout de alta confiança passa a ler o próximo pedido igual direto da camada de texto — custo zero e funcionando com a IA fora do ar. Só grava se reproduzir o resultado campo a campo e fechar a aritmética.
- **De-para inteligente** — determinístico (código/EAN/alias), fuzzy, semântico e desambiguação por LLM restrita ao catálogo; todo match aprovado vira aprendizado.
- **Validação contra catálogo** — nenhum item existe sem SKU válido no catálogo do cliente; a IA nunca inventa produto.
- **Revisão humana (aprovar / reprovar)** — reprovar exige motivo, que vira o corpo do e-mail automático ao comprador.
- **Reconciliação de ingestão** — dupla fonte (webhook + varredura) garante que nenhuma mensagem se perca.
- **Agente de WhatsApp** — oferece apenas itens do catálogo e sempre confirma itens, quantidades, endereço e pagamento do cadastro antes de finalizar.
- **Custo de IA rastreado por cliente** — toda chamada grava tokens e custo; o painel mostra consumo e economia do layout aprendido.
- **Monitoramento próprio** — erros viram eventos; a queda de um processo é detectada pela ausência do sinal de vida — tudo em uma tela.
- **Idempotência ponta a ponta** — deduplicação por message-id e wamid; reprocessar nunca duplica pedido no ERP.

## 8 INTEGRAÇÃO COM O ERP

A integração segue o modelo self-service, com duas pontas possíveis (excluentes entre si):

- **Entrada (pull)** — o ERP do contratante consome a API documentada da Softeum usando a chave de API gerada pelo Admin de TI no próprio painel.

- **Saída (push)** — a Softeum entrega o pedido diretamente no endpoint do ERP, via conector Generic REST/Webhook.
- **Autenticação do push** — token no header, OAuth2 client credentials ou OAuth2 authorization code (refresh token renovável).
- **Formato é configuração, não código** — cada ERP recebe o pedido no seu formato via template por cliente; campos inexistentes são barrados no cadastro.
- **Idempotência e limites** — criação de pedido idempotente por chave de deduplicação; rate-limit e concorrência por ERP.

## 9 SEGURANÇA E MULTI-TENANCY

- **Isolamento por cliente** — tenant\_id em toda tabela; RLS filtra por cliente em leitura e escrita.
- **Credenciais criptografadas** — tokens de ERP e OAuth criptografados em repouso; nunca em texto puro nem no navegador.
- **Segredos apenas no backend** — chaves vivem nos workers e Edge Functions.
- **Justiça entre clientes** — limite de concorrência por cliente evita que o pico de um afete os demais.
- **Idempotência** — reprocessamentos e retentativas nunca duplicam pedidos no ERP.

## 10 IDIOMAS DISPONÍVEIS

- Português — Brasil

## 11 REQUISITOS DO CLIENTE

A implantação é colaborativa. Para o sucesso do projeto, o contratante deverá:

- Definir um ponto focal para a execução do projeto de implantação.
- Indicar as caixas de e-mail e/ou o número de WhatsApp a monitorar e conceder as autorizações (OAuth / credenciais).
- Fornecer o catálogo de produtos (SKU, nome, unidade, preço, EAN e aliases) para importação.
- Fornecer o cadastro dos clientes finais.
- Disponibilizar o acesso e a documentação da API do ERP (pull) ou o endpoint e as credenciais (push).
- Programar um período de testes para validação da extração, do de-para e da integração.

## 12 SUPORTE

O cliente abre e acompanha chamados pelo site institucional (softeum.com.br, aba de suporte), com o mesmo e-mail e senha da plataforma. Qualquer usuário cadastrado tem acesso, sem distinção de perfil. Cada chamado recebe protocolo próprio, prioridade (P1/P2/P3) e permite anexos; todos os usuários da empresa veem os chamados do próprio cliente.